

**Creación de un modelo de inteligencia artificial avanzada: un árbol de decisión para la
predicción de riesgo de infarto cardíaco**

Yuliana Arango López

Tecnológica del Oriente

Electiva - Inteligencia Artificial Avanzada

Carlos Carrascal Avendaño

31 de julio de 2026

Resumen

Este informe documenta el diseño, entrenamiento y evaluación de un árbol de decisión para estimar el riesgo de infarto cardíaco a partir de 10 variables clínicas, siguiendo la estrategia de Aprendizaje Basado en Retos. Se utilizó una versión del conjunto de datos clásico de enfermedad cardíaca de Cleveland (294 pacientes), tras eliminar tres variables con más del 60% de valores faltantes. El modelo, ajustado mediante búsqueda de hiperparámetros con validación cruzada, alcanzó un accuracy de 77.8%, un recall de 75.0% y un AUC-ROC de 0.873 sobre el conjunto de prueba. Se seleccionó un árbol de decisión, en lugar de una red neuronal profunda, por su interpretabilidad directa y por ser una técnica adecuada para conjuntos de datos clínicos de tamaño moderado. El informe incluye además un análisis de equidad por sexo, motivado por evidencia clínica documentada sobre el subdiagnóstico de infartos en mujeres, y una discusión de las implicaciones éticas de aplicar este tipo de modelos en un contexto de salud real.

Palabras clave: árbol de decisión, aprendizaje automático, predicción de infarto, interpretabilidad, equidad algorítmica.

1. Introducción y planteamiento del problema

1.1 Contexto y relevancia

Las enfermedades cardiovasculares son la principal causa de muerte a nivel mundial, y la detección temprana del riesgo de infarto puede marcar la diferencia entre una intervención oportuna y un desenlace fatal. Tradicionalmente, esta detección se apoya en el criterio clínico y en escalas de riesgo estandarizadas; sin embargo, la literatura reciente muestra que los modelos de aprendizaje automático pueden apoyar este proceso al identificar patrones no evidentes en los datos clínicos de un paciente (Srinivasan et al., 2023).

Un problema particularmente relevante, y que este informe aborda de manera explícita, es que el criterio clínico tradicional para reconocer un infarto no funciona igual de bien para todos los pacientes. Existe evidencia consistente de que los síntomas de infarto en mujeres difieren de la presentación considerada "típica", históricamente definida a partir de poblaciones mayoritariamente masculinas, lo que ha derivado en tasas más altas de subdiagnóstico y demoras en la atención de mujeres (Cardeillac et al., 2022; Dawson et al., 2023).

1.2 Justificación de la selección del problema

Se seleccionó este problema por tres razones. Primero, su relevancia clínica y social es indiscutible: una predicción de riesgo más precisa y accesible puede apoyar decisiones de cribado en contextos con recursos limitados. Segundo, el conjunto de datos utilizado es un estándar de facto en la literatura de aprendizaje automático aplicado a salud, lo que permite comparar los resultados obtenidos con los reportados por otros autores. Tercero, el problema exige explícitamente evaluar la efectividad del modelo en la toma de decisiones, no solo su precisión estadística, lo que hace pertinente examinar si el modelo funciona igual de bien para hombres y mujeres.

2. Revisión de la literatura

2.1 Aprendizaje automático aplicado a la predicción de enfermedad cardíaca

El conjunto de datos de enfermedad cardíaca de Cleveland, sobre el cual se basa este trabajo, ha sido ampliamente estudiado en la literatura. Srinivasan et al. (2023) compararon ocho clasificadores de aprendizaje automático, incluyendo árboles de decisión, sobre datos de este mismo dominio, encontrando que técnicas como los árboles de decisión y los bosques aleatorios ofrecen un desempeño competitivo frente a modelos más complejos cuando el conjunto de datos es de tamaño moderado. Esta literatura respalda la elección metodológica de este informe: no se requiere necesariamente una arquitectura de aprendizaje profundo para obtener resultados clínicamente útiles en este tipo de problema.

2.2 Interpretabilidad de los árboles de decisión en sistemas de apoyo clínico

Xu (2023), en una revisión sistemática sobre interpretabilidad de sistemas de apoyo a la decisión clínica basados en inteligencia artificial, identifica los árboles de decisión, junto con la regresión logística, como modelos intrínsecamente interpretables: su estructura permite trazar de forma directa la relación entre las variables de entrada y la predicción final, algo que los modelos de tipo caja negra —como las redes neuronales profundas— no ofrecen sin recurrir a técnicas adicionales de explicabilidad. Esta característica es especialmente relevante en medicina, donde un profesional de la salud necesita poder justificar clínicamente una decisión apoyada por un modelo, y no solo confiar en un número de probabilidad.

2.3 Diferencias de género en el diagnóstico de infarto

La motivación central del análisis de equidad de este informe proviene de evidencia clínica consolidada. Cardeillac et al. (2022), en una revisión sistemática con metaanálisis, documentan

diferencias reales en la presentación de síntomas de infarto entre mujeres y hombres, más allá de percepciones anecdóticas. Dawson et al. (2023), en un estudio de cohorte poblacional con pacientes atendidos por servicios de emergencia, encontraron que las mujeres con dolor torácico agudo reciben con menor frecuencia pruebas diagnósticas inmediatas y experimentan demoras en la atención guiada por protocolo, en comparación con hombres con presentaciones clínicas similares. De manera más específica, Guethoff et al. (2024) mostraron, mediante un estudio con viñetas clínicas aleatorizadas por género, que incluso cirujanos experimentados reconocen con menor precisión los síntomas de infarto postoperatorio cuando el paciente descrito es mujer.

2.4 Consideraciones éticas y de equidad en IA aplicada a salud

La literatura sobre inteligencia artificial en salud advierte que un modelo entrenado sobre datos clínicos históricos puede heredar los sesgos presentes en esos datos, incluso cuando ninguna variable sensible se usa de forma explícita como predictor (Timmons et al., 2023). Este riesgo es directamente relevante para este proyecto: si el criterio clínico humano ya presenta un sesgo documentado por sexo, como se describió en la sección 2.3, es razonable preguntarse si un modelo entrenado sobre datos que reflejan ese mismo contexto clínico podría reproducir un patrón similar. Esa es precisamente la pregunta que se examina en la sección 5.2.

3. Diseño del algoritmo

3.1 Datos de entrada

Se utilizó una versión del conjunto de datos de enfermedad cardíaca de Cleveland, compuesta originalmente por 294 pacientes y 14 variables. El conjunto marca los valores faltantes con el símbolo "?" en lugar de dejarlos vacíos. Tres variables —pendiente del segmento ST (slope), número de vasos principales (ca) y resultado de la prueba de talio (thal)— presentaron porcentajes

de valores faltantes de 64.6%, 99.0% y 90.5% respectivamente, por lo que se descartaron del análisis: con un porcentaje de datos ausentes tan alto, cualquier técnica de imputación introduciría más ruido que información real. Tras la limpieza, el modelo quedó compuesto por 10 variables predictoras: edad, sexo, tipo de dolor de pecho, presión arterial en reposo, colesterol, glucemia en ayunas, resultados electrocardiográficos en reposo, frecuencia cardíaca máxima alcanzada, angina inducida por ejercicio y depresión del segmento ST inducida por ejercicio. La variable objetivo (num) es binaria: 0 indica ausencia de riesgo de infarto y 1 indica presencia de riesgo, con una distribución de 188 pacientes sin riesgo (63.9%) y 106 con riesgo (36.1%).

3.2 Arquitectura del algoritmo: árbol de decisión

Se entrenó un árbol de decisión de clasificación (Decision Tree Classifier). A diferencia de una red neuronal, que combina todas las variables mediante pesos numéricos ajustados de forma iterativa durante muchas épocas, un árbol de decisión construye una secuencia de preguntas binarias sobre una variable a la vez, seleccionando en cada paso la pregunta que mejor separa a los pacientes con y sin riesgo, de acuerdo con un criterio de impureza (gini o entropía). Se prefirió esta arquitectura sobre una red neuronal profunda por dos razones alineadas con la literatura revisada: primero, con solo 294 pacientes, un árbol de decisión bien ajustado tiende a igualar o superar a una red neuronal, que generalmente requiere más datos para generalizar bien (Srinivasan et al., 2023); segundo, y de manera más importante para un problema clínico, su interpretabilidad directa permite explicar cada predicción como una cadena legible de condiciones, en lugar de como una combinación no interpretable de pesos (Xu, 2023).

3.3 Ajuste de hiperparámetros y optimización

Siguiendo el resultado de aprendizaje de esta actividad, que exige ajustar parámetros y evaluar su efecto en la efectividad del modelo, se diseñó una búsqueda exhaustiva de hiperparámetros

(GridSearchCV) con validación cruzada de 5 particiones, optimizando el F1-score. Se definieron como hiperparámetros a explorar: la profundidad máxima del árbol (3, 4, 5, 6, 8 o sin límite), el número mínimo de muestras para dividir un nodo, el número mínimo de muestras por hoja, y el criterio de división (gini o entropía). El F1-score se eligió como métrica objetivo de la búsqueda, en lugar del accuracy, porque el conjunto de datos está moderadamente desbalanceado (63.9% sin riesgo frente a 36.1% con riesgo).

3.4 Poda y control de la profundidad (regularización)

Dado el riesgo de sobreajuste inherente a un árbol sin restricciones, que puede crecer hasta memorizar cada paciente individual del conjunto de entrenamiento, se incorporó como decisión de diseño un límite explícito a la profundidad máxima y al número mínimo de muestras por hoja y por división. Esta forma de poda previa (pre-pruning) cumple, en un árbol de decisión, un papel equivalente al del Dropout y el early stopping en una red neuronal: evita que el modelo memorice pacientes individuales en lugar de aprender un patrón generalizable, sacrificando parte del ajuste al conjunto de entrenamiento a cambio de una mejor generalización a datos nuevos.

4. Implementación y pruebas

4.1 Entorno y herramientas

El algoritmo se implementó en Python, utilizando la biblioteca scikit-learn para la construcción, ajuste de hiperparámetros y evaluación del árbol de decisión, pandas y numpy para el preprocesamiento de datos, y Google Colab como entorno de ejecución en la nube. El dataset se cargó directamente en el entorno de Colab, ya sea subiéndolo al panel de archivos o mediante el botón de carga del notebook.

4.2 Preprocesamiento de los datos

Tras eliminar las tres variables con exceso de valores faltantes descritas en la sección 3.1, las variables restantes con valores faltantes menores (colesterol, glucemia en ayunas, entre otras) se completaron con la mediana de cada columna, dado que su proporción de datos ausentes era baja (entre 0.3% y 7.8%). Los datos se dividieron en tres conjuntos, con estratificación para preservar la proporción de pacientes con y sin riesgo en cada partición: 70% para entrenamiento (205 pacientes), 15% para validación (44 pacientes) y 15% para prueba (45 pacientes). El conjunto de prueba se mantuvo completamente aislado hasta la evaluación final, reportada en la sección 4.4.

4.3 Proceso de entrenamiento

El conjunto de entrenamiento y validación se combinó durante la búsqueda de hiperparámetros descrita en la sección 3.3, evaluando cada combinación mediante validación cruzada de 5 particiones. La combinación de hiperparámetros seleccionada por la búsqueda fue: criterio gini, profundidad máxima de 8, mínimo de 2 muestras por hoja y mínimo de 2 muestras para dividir un nodo. Con esta configuración, el árbol final se reentrenó sobre la totalidad de los datos de entrenamiento y validación antes de evaluarse sobre el conjunto de prueba, nunca antes visto por el modelo.

4.4 Resultados obtenidos

Sobre el conjunto de prueba, el modelo obtuvo los resultados que se resumen en la Tabla 1.

Métrica	Valor	Interpretación
Accuracy	77.8%	Proporción total de predicciones correctas
Precisión	66.7%	De los pacientes marcados con riesgo, cuántos sí lo tenían
Recall (sensibilidad)	75.0%	De los pacientes con riesgo real, cuántos detectó el modelo

F1-score	70.6%	Balance entre precisión y recall
AUC-ROC	0.873	Capacidad del modelo para distinguir entre clases

Tabla 1. Desempeño del árbol de decisión sobre el conjunto de prueba.

Un AUC-ROC de 0.873 indica que el modelo distingue razonablemente bien entre pacientes con y sin riesgo, muy por encima de un clasificador aleatorio (AUC de 0.5). El recall de 75.0% es un dato clínicamente relevante: en un contexto de cribado de riesgo cardíaco, omitir un caso de riesgo real (falso negativo) suele considerarse más costoso que generar una alerta que luego se descarta (falso positivo), por lo que priorizar el recall sobre la precisión pura es una decisión metodológica razonable para este dominio.

La variable más importante para el modelo, con una diferencia considerable sobre el resto, fue la angina inducida por ejercicio (exang), que además constituye la pregunta raíz del árbol: el primer criterio que el modelo evalúa para cualquier paciente nuevo. Le siguen, en orden de importancia, la frecuencia cardíaca máxima alcanzada, el tipo de dolor de pecho y el nivel de colesterol. Este patrón es consistente con lo reportado por Srinivasan et al. (2023), quienes también identifican el dolor de pecho y las variables relacionadas con la respuesta al ejercicio como predictores centrales en este tipo de conjuntos de datos. La variable sexo, en contraste, ocupó un lugar relativamente bajo en la importancia de variables (aproximadamente 3.2%), un dato que se retoma en la sección 5.2 al analizar la equidad del modelo.

5. Evaluación y reflexión

5.1 Desempeño técnico

Los resultados obtenidos (accuracy de 77.8%, recall de 75.0% y AUC-ROC de 0.873) son consistentes con el rango de desempeño reportado por otros trabajos que aplican árboles de

decisión y clasificadores comparables sobre este mismo conjunto de datos (Srinivasan et al., 2023). Esto respalda la decisión de diseño tomada en la sección 3.2: un árbol de decisión bien ajustado es una herramienta adecuada, y no una alternativa menor frente a una red neuronal, para un problema clínico de este tamaño y naturaleza.

5.2 Consideraciones éticas y de equidad

Motivados por la evidencia clínica revisada en la sección 2.3 sobre el subdiagnóstico de infartos en mujeres, se calculó el accuracy del modelo de forma separada para pacientes mujeres y hombres dentro del conjunto de prueba. Los resultados se presentan en la Tabla 2.

Grupo	N (prueba)	Accuracy
Mujeres (sex = 0)	11	81.8%
Hombres (sex = 1)	34	76.5%

Tabla 2. Desempeño del modelo desagregado por sexo.

En este conjunto de prueba específico, el modelo no mostró un desempeño menor para las pacientes mujeres; de hecho, el accuracy fue ligeramente superior en el subgrupo de mujeres (81.8%) que en el de hombres (76.5%). Es importante interpretar este resultado con la cautela estadística que amerita: el subgrupo de mujeres en el conjunto de prueba es muy pequeño (11 pacientes), por lo que esta diferencia podría deberse en buena medida al azar y no debe interpretarse como evidencia sólida de que el modelo es equitativo por sexo.

Lo que sí es posible afirmar, con base en este ejercicio, es que la brecha de género documentada en la literatura clínica (Cardeillac et al., 2022; Dawson et al., 2023; Guethoff et al., 2024) no proviene necesariamente del análisis estadístico de los datos, sino de decisiones humanas: qué síntomas se consideran "típicos", a quién se le ordenan pruebas diagnósticas de forma inmediata, y qué información llega finalmente a un conjunto de datos como el utilizado en este informe. Un

modelo entrenado sobre datos ya sesgados por decisiones clínicas previas puede reproducir ese sesgo aunque la variable sexo tenga baja importancia directa, precisamente porque ese sesgo puede estar codificado indirectamente en otras variables del historial clínico del paciente (Timmons et al., 2023).

5.3 Limitaciones

Se identifican tres limitaciones relevantes. Primero, el tamaño de la muestra (294 pacientes, y solo 45 en el conjunto de prueba) es demasiado pequeño para sacar conclusiones definitivas sobre equidad; un análisis riguroso requeriría un conjunto de datos considerablemente más grande y, de manera ideal, proveniente de más de un centro clínico. Segundo, el conjunto de datos no incluye información sobre raza, nivel socioeconómico u otros factores que la literatura también identifica como fuentes de disparidad en el diagnóstico cardiovascular, por lo que este informe solo puede evaluar una dimensión de un problema de equidad más amplio. Tercero, ningún modelo entrenado sobre datos clínicos históricos debería usarse como única fuente de decisión: como advierte la literatura sobre interpretabilidad de sistemas de apoyo clínico (Xu, 2023), el valor de un modelo como este está en apoyar —no en reemplazar— el juicio de un profesional de la salud.

5.4 Trabajo futuro

Como líneas de trabajo futuro se proponen: repetir este análisis de equidad sobre un conjunto de datos considerablemente más grande antes de considerar cualquier aplicación real del modelo; incorporar variables adicionales asociadas a disparidades documentadas en la literatura, por ejemplo el tiempo transcurrido hasta la realización de pruebas diagnósticas; y complementar el árbol de decisión con métodos de conjunto (random forest, gradient boosting) que podrían mejorar el desempeño sin sacrificar por completo la interpretabilidad, mediante las mismas técnicas de importancia de variables utilizadas en este informe.

6. Conclusiones

Este informe demostró la viabilidad de un árbol de decisión, ajustado mediante búsqueda de hiperparámetros con validación cruzada, para estimar el riesgo de infarto cardíaco a partir de variables clínicas de rutina, alcanzando un accuracy de 77.8% y un AUC-ROC de 0.873 sobre un conjunto de datos de tamaño moderado. Se justificó la elección de un árbol de decisión, en lugar de una arquitectura de aprendizaje profundo, con base en su interpretabilidad directa, una característica que la literatura reciente identifica como un requisito, y no un lujo, para la adopción responsable de inteligencia artificial en contextos clínicos. El análisis de equidad por sexo no mostró evidencia de un desempeño desfavorable para las pacientes mujeres en este conjunto de prueba específico, pero el tamaño reducido de la muestra impide generalizar esa conclusión, por lo que cualquier extensión futura de este trabajo debe tratar la evaluación de equidad como un paso obligatorio, y no opcional, antes de cualquier aplicación real.

Referencias

- Cardeillac, M., Lefebvre, F., Baicry, F., Le Borgne, P., Gil-Jardiné, C., Cipolat, L., Peschanski, N., & Abensur Vuillaume, L. (2022). Symptoms of infarction in women: Is there a real difference compared to men? A systematic review of the literature with meta-analysis. *Journal of Clinical Medicine*, 11(5), Article 1319. <https://doi.org/10.3390/jcm11051319>
- Dawson, L. P., Nehme, E., Nehme, Z., Davis, E., Bloom, J., Cox, S., Nelson, A. J., Okyere, D., Anderson, D., Stephenson, M., Lefkovits, J., Taylor, A. J., Nicholls, S. J., Cullen, L., Kaye, D., Smith, K., & Stub, D. (2023). Sex differences in epidemiology, care, and outcomes in patients with acute chest pain. *Journal of the American College of Cardiology*, 81(10), 933-945. <https://doi.org/10.1016/j.jacc.2022.12.025>
- Guethoff, S., Kraft, R., Riege, M., Grinninger, C., & Krajewski, K. (2024). Females at a clear disadvantage with postoperative myocardial infarction symptoms. *Journal of Cardiovascular Development and Disease*, 11(11), Article 371. <https://doi.org/10.3390/jcdd11110371>
- Srinivasan, S., Gunasekaran, S., Mathivanan, S. K., Benjula Anbu Malar, M. B., Jayagopal, P., & Dalu, G. T. (2023). An active learning machine technique based prediction of cardiovascular heart disease from UCI-repository database. *Scientific Reports*, 13, Article 13588. <https://doi.org/10.1038/s41598-023-40717-1>
- Timmons, A. C., Duong, J. B., Simo Fiallo, N., Lee, T., Vo, H. P. Q., Ahle, M. W., Comer, J. S., Brewer, L. C., Frazier, S. L., & Chaspari, T. (2023). A call to action on assessing and mitigating bias in artificial intelligence applications for mental health. *Perspectives on Psychological Science*, 18(5), 1062-1096. <https://doi.org/10.1177/17456916221134490>

Xu, A. (2023). Interpretability of clinical decision support systems based on artificial intelligence from technological and medical perspective: A systematic review. *Journal of Healthcare Engineering*, 2023, Article 9919269. <https://doi.org/10.1155/2023/9919269>